

De la donnée brute à la décision : Bank Marketing

Peut-on prédire la souscription d'un client à un dépôt bancaire ?

Problématique : Quels sont les facteurs qui influencent le plus la souscription d'un client à un dépôt à terme bancaire lors d'une campagne marketing ?

Présenté par : Marianna MANENKOVA

Message principal : Notre objectif est de comprendre les données, construire un modèle de classification et tirer des conclusions utiles pour une décision marketing.

Une banque qui cherche à mieux cibler ses campagnes

Le dataset **Bank Marketing** (UCI / Kaggle) provient d'une campagne de télémarketing menée par une banque portugaise. Des conseillers contactent des clients par téléphone pour leur proposer un **dépôt à terme** (*term deposit*). À l'issue de chaque appel, le client répond **yes** (souscription) ou **no** (refus).

Cibler mieux

Identifier les profils clients les plus susceptibles de souscrire

Réduire les coûts

Diminuer les appels inutiles et optimiser les ressources commerciales

Décider mieux

Transformer les données en aide à la décision stratégique

 L'enjeu n'est pas seulement de prédire, mais d'aider la banque à mieux décider.

Le dataset Bank Marketing : 11 162 clients, 17 variables

Caractéristiques principales

- **11 162** observations (clients contactés)
- **17 variables** explicatives
- Variable cible : **deposit** (yes / no)
- Problème : **classification binaire**


Variables clés

- **Démographiques** : age, job, marital, education
- **Financières** : balance, housing, loan
- **Campagne** : contact, duration, campaign, pdays, previous, poutcome




De la donnée brute à la décision : notre démarche en 9 étapes

Nous avons suivi la logique du cours : partir de la donnée brute, la rendre exploitable, puis l'utiliser pour produire une décision éclairée.



❏ Chaque étape prépare la suivante : un nettoyage rigoureux garantit des modèles fiables et des interprétations valides.

Premiers constats : un dataset bien équilibré



Distribution de la variable cible

Le dataset est **presque équilibré** : 52,5 % de non-souscriptions et 47,5 % de souscriptions. Cet équilibre est favorable à la modélisation, car le modèle ne sera pas biaisé vers une seule classe.

Autres constats clés

- Métiers dominants : **management, blue-collar, technician, admin**
- Clients **mariés** majoritaires
- Solde bancaire médian : **~450 €**

Un nettoyage rigoureux pour une base exploitable

Valeurs manquantes traitées

- **job** : 0,6 % unknown → remplacé par le mode
- **education** : 4,5 % unknown → remplacé par le mode
- **contact** : 21 % unknown → **conservé** comme catégorie à part entière
- **poutcome** : 74,6 % unknown → remplacé par "none"

Autres traitements

- Aucun doublon exact détecté
- Outliers traités avec la règle $1,5 \times IQR$ sur *campaign* et *balance*
- Encodage complet : dataframe final **100 % numérique**

9 556

Clients conservés

Après nettoyage et suppression des outliers

85,6%

Données retenues

Taux de conservation du dataset initial


100%

Variables numériques

Dataframe prêt pour la modélisation

📄 Le nettoyage permet de travailler sur une base plus cohérente et exploitable.

Quels profils souscrivent le plus ?




Conclusions principales

- Les **étudiants** ont le taux de souscription le plus élevé : **~76 %**
- Les **retraités** suivent avec **~67 %**
- Les **blue-collar** et **entrepreneurs** : seulement **~37 %**
- Les clients avec un **solde plus élevé** souscrivent davantage
- La médiane du *balance* est plus haute chez les souscripteurs

❏ Certains profils sont plus réceptifs à l'offre bancaire. Cela peut aider la banque à mieux cibler ses campagnes.

La durée d'appel : le signal le plus discriminant



Ce que révèle la durée d'appel

- Clients ayant **souscrit** : durée moyenne **~8,9 minutes**
- Clients n'ayant **pas souscrit** : durée moyenne **~3,8 minutes**
- La durée est **2,3 fois plus élevée** chez les souscripteurs



Nuance importante

La durée d'appel est connue **pendant ou après** l'appel. Elle est donc très utile pour **comprendre** la souscription, mais plus limitée pour **décider à l'avance** quels clients appeler.

Deux modèles de classification comparés

Nous avons testé deux algorithmes : la **régression logistique** (modèle interprétable) et la **Random Forest** (modèle non-linéaire). Les deux modèles ont été évalués sur les mêmes données test avec les mêmes métriques.

Métrique	Régression logistique	Random Forest	Écart	Avantage
Accuracy	0,809	0,823	+0,014	Random Forest
Precision	0,808	0,792	-0,016	Régression logistique
Recall	0,785	0,851	+0,066	Random Forest
F1-score	0,796	0,821	+0,025	Random Forest
ROC-AUC	0,887	0,900	+0,013	Random Forest

📌 **Le Random Forest est légèrement meilleur.** Il obtient un meilleur recall, un meilleur F1-score et un meilleur ROC-AUC. Il identifie donc mieux les clients susceptibles de souscrire. Le modèle ne sert pas seulement à obtenir un score : il permet de **prioriser les clients les plus susceptibles de répondre positivement**.

De la donnée à la décision : ce que nous avons appris

✓ Dataset exploitable

Après nettoyage, **9 556 clients** conservés,
base 100 % numérique

🌲 Meilleur modèle

Random Forest : ROC-AUC 0,900, Recall
0,851, F1-score 0,821

🔑 Variables clés

Durée d'appel, métier, solde bancaire,
historique de campagne

Recommandations pour la banque

01

Prioriser les profils à fort taux de souscription : **étudiants, retraités, clients avec solde positif**

03

Utiliser le modèle comme **outil d'aide à la décision**, pas comme décision automatique

02

Réduire les appels répétés aux profils peu réceptifs (**blue-collar, entrepreneurs**)

04

Tester le modèle sur de **nouvelles campagnes** avant un déploiement réel